

基于改进 YOLOv5s 的复杂装配场景多尺度零件识别^{*}

郑亮亮,郭宇,蒲俊,周海浪,齐健文
(南京航空航天大学机电学院,南京 210016)

摘要:针对当前 AR 装配引导系统场景感知能力较弱,对复杂装配场景中多尺度零件和遮挡零件识别效果不佳的问题,提出一种基于改进 YOLOv5s 的复杂装配场景零件检测算法。首先,通过多尺度特征融合,将新增浅层特征图输入到特征融合网络中,提高对小零件的识别效果;其次,在主干网络中增加卷积注意力模块(convolutional block attention module,CBAM)、Transformer 编码器模块,提高对于重要特征的捕获能力,抑制冗余特征;最后,采用 CIoU 作为边界框损失函数,并将传统非极大值抑制(non-maximum suppression,NMS)算法改为 DIoU_NMS,提高零件被遮挡时的识别效果。实验结果表明改进后的 YOLOv5s 算法识别精度达到 96.2%,相比原始算法提高了 2.9%,提高了对多尺度零件特别是小零件及零件被遮挡时的检测性能,且满足实时性要求。

关键词:AR 装配;多尺度零件识别;YOLOv5s;注意力机制;遮挡检测

中图分类号:TH16;TG502

文献标识码:A

Multi-Scale Part Recognition in Complex Assembly Scene Based on Improved YOLOv5s

ZHENG Liangliang, GUO Yu, PU Jun, ZHOU Hailang, QI Jianwen

(College of Mechanical and Electrical Engineering, Nanjing University of Aeronautics and Astronautics, Nanjing 210016, China)

Abstract: Aiming at the weak scene perception ability of current AR assembly guidance system and poor recognition effect of multi-scale parts and occlusion parts in complex assembly scenes, a complex scene part detection algorithm based on improved YOLOv5s is proposed. Firstly, through multi-scale feature fusion, the new shallow feature map is input into the feature fusion network to improve the recognition effect of small parts. Secondly, a convolutional block attention module (CBAM) and a Transformer encoder Module are added to the trunk network to improve the ability to capture important features and suppress redundant features. Finally, CIoU is used as the bounding box loss function, and the traditional non-maximum suppression (NMS) algorithm is changed to DIoU_NMS to improve the recognition effect when parts are blocked. Experimental results show that the recognition accuracy of the improved YOLOv5s algorithm reaches 96.2%, which is 2.9% higher than the original algorithm. It improves the detection performance of multi-scale parts, especially small parts and parts blocked, and meets the real-time requirements.

Key words: AR assembly; multiscale part identification; YOLOv5s; attention mechanism; occlusion detection

0 引言

当前复杂装配场景中零件数量种类多,尺寸多样,既包含大零件也存在螺钉、螺栓等细小零件,尺寸往往相差几十甚至几百倍;零件摆放过程中存在遮挡现象,包括零件与零件之间的遮挡以及其他物体对零件的遮挡等问题。基于机器视觉的零件识别技术中相机在同一位置往往只能检测到大尺寸零件,而忽视细小零件和被遮挡的零件。AR 装配能够对生产装配过程进行可视化引导^[1],而对零件的精准识别是实现装配智能引导的基础。因此提高复杂装配场景下零件识别的精度对于提高 AR 装配引导系统的场景感知能力具有重要意义。

在对提高复杂装配场景零件的检测性能问题上,许多学者对此进行了研究,主要包括基于机器视觉的图像特征检测方法以及基于深度学习的目标检测算法。ZHENG 等^[2]设计了一种基于 ORB 特征匹配的自动定位抓取方法,用于解决机械臂对工业零件的定位和抓取问题;陈小佳^[3]为解决零件表面的反光问题,采用机器视觉检测方法,一定程度上排除了噪声干扰;SUN 等^[4]针对小样本零件的识别问题,提出了一种基于相对熵的零件识别与定位方法;田中可等^[5]提出一种利用随机森林分类器对提取的深度图像差分特征进行分类的方法,用于对圆锥圆柱减速器装配体及零件的识

收稿日期:2022-08-11

^{*} 基金项目:国防基础科研项目(JCKY2018203A001,JCKY2019204A004)

作者简介:郑亮亮(1997—),男,硕士研究生,研究方向为智能制造,(E-mail)zhengll@nuaa.edu.cn;通信作者:郭宇(1971—),男,教授,博士生导师,研究方向为制造物联技术、智能制造与工业大数据,(E-mail)guoyu@nuaa.edu.cn。

别;王一等^[6]针对零件在复杂光照、遮挡、位姿变换、小零件漏检等情况下的识别精度不佳问题,提出了一种改进 Faster RCNN 算法;宋栓军等^[7]通过对 YOLOv3 模型改进以及锚框聚类,提高了对小零件的检测精度;LI 等^[8]针对工业机械零件缺乏数据样本问题,建立了一个基于 InceptionNet-V3 预训练模型的卷积神经网络模型;杨琳等^[9]针对零件定位精度差的问题,提出了一种改进 YOLOv4 算法的零件识别方法,通过改进优化算法和预测边界框,提高定位准确性;SHEU 等^[10]设计了一套基于 IDS-DLA 深度学习算法的钣金零件识别系统,用于解决钣金件的自动化识别问题。王向周等^[11]针对紧固机器人对螺栓的检测问题,利用深度相机获取点云并与 YOLOv5s-T 结合实现对螺栓的三维定位和排序。

上述针对零件检测的方法中,基于特征的检测方法要求零件具有复杂的纹理结构,不同零件间有较大的对比度^[12];基于深度学习对于同一角度距离下的多尺度及遮挡问题的检测性能较差。综合考虑模型大小、检测实时性以及准确性,本文提出了一种基于改进 YOLOv5s 的零件检测算法,用于对复杂装配场景中的多尺度零件进行检测。

1 YOLOv5s 算法及改进

1.1 YOLOv5 算法

YOLO 算法主要思想是利用同一个网络同时输出位置信息和类别信息^[13-16],到 2020 年 YOLO 算法发展到了第五代。YOLOv5 算法与原有相比在输入端增加了自适应图片缩放, Mosaic 数据增强, 自适应锚框计算;采用 CSPDarknet53 为主干网络;特征金字塔网络 (feature pyramid network, FPN) 与路径聚合网络 (path aggregation network, PAN) 相结合为特征提取网络,将浅层信息与深层信息融合提高检测性能。YOLOv5 系列根据通道数及模型大小分为 YOLOv5s、YOLOv5m、YOLOv5l、YOLOv5x, 模型大小依次增加^[17]。

原始的 YOLOv5s 算法输出端包含 3 个预测层,用于预测大、中、小 3 种尺寸目标,而过多的下采样导致目标的位置信息缺失,不利于对小目标的检测,对多尺寸零件检测效果较差且抗遮挡能力弱。

1.2 改进的 YOLOv5s 算法

本文对 YOLOv5s 算法进行改进,在自制的零件数据集上进行训练,利用训练好的模型对真实零件进行检测,实验流程如图 1 所示。

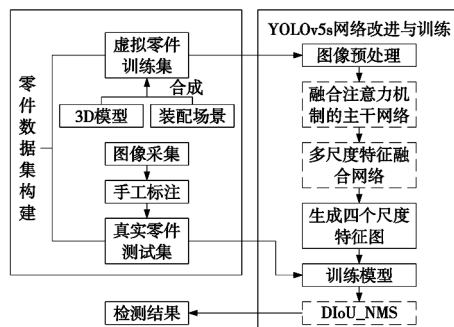


图 1 实验流程图

其中 YOLOv5s 网络主要从以下 3 个方面进行改进:①将注意力机制模块融合到主干网络中,提高在杂乱背景下的检测性能;②为提高对于细小零件的检测能力,在特征融合网络增加浅层特征图,防止小目标特征消失;③采用 CIoU 作为边界框损失函数, DIoU 作为非极大值抑制 (non-maximum suppression, NMS) 计算指标,减少因零件遮挡而导致漏检问题。改进后网络结构如图 2 所示。

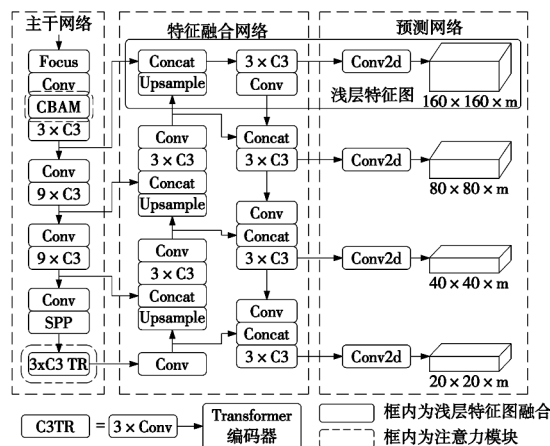


图 2 改进后的 YOLOv5s 网络结构

1.2.1 融合注意力机制

针对复杂装配场景中包含装配零件、工具等物体及杂乱背景,导致非目标零件的误识别问题,本文将 CBAM^[18]、Transformer^[19] 模块集成到主干网络中,用于提高网络性能,如图 3 所示。输入图像在经过 CBAM 模块后得到 4 倍下采样特征图,再经过两次下采样后传到 Transformer 编码模块,得到 32 倍下采样特征图。




图 3 融合注意力机制的主干网络

(1)CBAM 模块。CBAM 模块是一种简单高效的注意力机制,用于提高模型的表征能力,其结构如图 4 所示,包含 2 个独立的子模块:通道注意力模块和空间注意力模块。本文将 CBAM 模块集成到主干网络中,在经过通道注意力及空间注意力后将输出结果传递到下一层及特征提取网络中,以提高零件检测性能。

(2)Transformer 模块。Transformer 模型是一个用纯注意力机制搭建的模型,广泛应用于图像处理中。Transformer 模块包含编码器和解码器两部分,编码部分结构如图 5 所示,利用编码器进行特征提取,Transformer 编码器增加了捕获不同信息的能力,可以利用自注意力机制来挖掘潜在特征,在高密度遮挡对象上具有更好的性能^[20],可提升零件在被遮挡时的检测性能,提高模型抗遮挡能力。

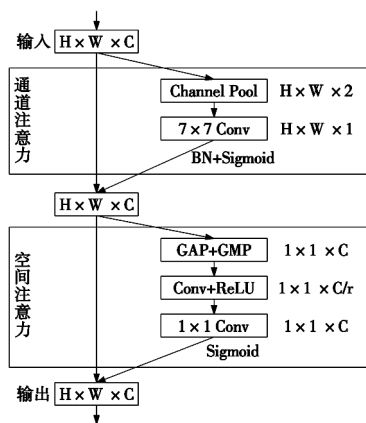


图4 CBAM模块结构




图5 Transformer 编码部分结构图

1.2.2 多尺度特征融合

针对原始网络对螺栓螺母等小零件的漏检问题,对特征融合网络进行改进。原始的YOLOv5s算法中输入图像在主干网络中将3次下采样特征图输入到特征融合网络中,如图6a所示。而过多的下采样会导致目标的位置信息缺失,不利于对小目标的检测,因此将下采样4倍后的特征图输入到FPN中与深层语义信息结合后输入到PAN中,自底向上传递目标位置信息。如图6b所示。新增的特征图分辨率高,拥有更加丰富的位置信息,将主干网络中更多的小零件信息输入到特征提取网络中,从而提高对小零件的检测效果。

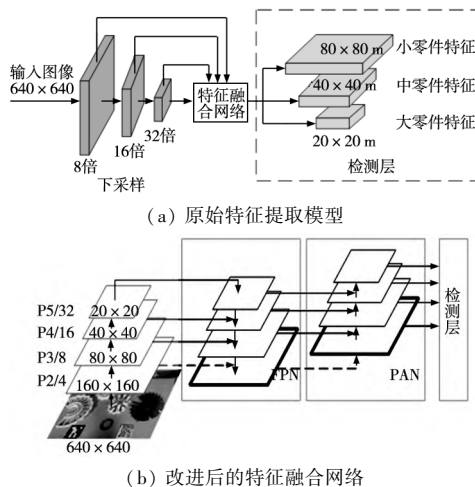


图6 多尺度特征融合网络对比

1.2.3 损失函数与NMS优化

(1)CIoU。YOLOv5s算法中损失函数包括边界框损失、分类损失和置信度预测损失^[21],其中边界框损失采用GIOU作为损失函数^[22],计算公式如下:

$$L_{GIOU} = 1 - GIOU \quad (1)$$

$$GIOU = IOU - \frac{|C| - |A \cup B|}{|C|} \quad (2)$$

$$IOU = \frac{A \cap B}{A \cup B} \quad (3)$$

式中: A 、 B 为预测框和真实框, C 为能够包围两框的最小矩形框。

针对GIOU损失当预测框在真实框内部时,无法确定预测框的位置状态,此时GIOU计算值与IOU相同的问题,采用CIoU损失^[23]作为边界框损失函数,CIoU可以反映检测框的长宽比以及衡量锚框与真实框之间

的比例一致性,可以在预测框与真实框没有重叠时向重叠区域增加的方向进行优化,计算公式为:

$$L_{CIoU} = 1 - IOU + \frac{\rho^2(b, b^{gt})}{c^2} + \alpha v \quad (4)$$

$$v = \frac{4}{\pi^2} \left(\arctan \frac{w^{gt}}{h^{gt}} - \arctan \frac{w}{h} \right)^2 \quad (5)$$

$$\alpha = \frac{v}{(1 - IOU) + v} \quad (6)$$

式中: ρ 为预测框与真实框两中心点之间的距离, c 为能包含两矩形框的最小矩形的对角线的长度, w^{gt} 、 h^{gt} 为真实框的宽和高, w 、 h 为预测框的宽和高。

(2)DIoU_NMS。针对YOLOv5s算法中采用IoU作为NMS计算指标,当零件相互遮挡时,容易将正确预测框抑制的问题,对NMS算法进行改进,改进后算法流程如表1所示。

表1 DIoU_NMS算法

算法1:DIoU_NMS算法
输入:所有预测框 B ;对应得分 S ;阈值 N_t
输出:预测框 D ;对应得分 S
1. $D \leftarrow \{\}$
2. While B 不为空 do
3. $m \leftarrow S$ 取最大值的点; $M \leftarrow B_m$;
4. $D \leftarrow D \cup M$; $B \leftarrow B - B_m$;
5. for B_i in B do
6. if $DIoU(M, B_i) \geq N_t$ // $DIoU$ 大于等于阈值
7. $B \leftarrow B - B_i$; $S \leftarrow S - S_i$; // 更新集合 B 和 S
8. return D, S

采用DIoU作为NMS的计算指标,计算公式如式(7)所示。

$$DIoU = IOU - \frac{\rho^2(b, b^{gt})}{c^2} \quad (7)$$

在计算时不仅考虑两框的重叠区域,同时两者中心点间的距离也作为影响因素,一定程度上减少了因零件之间相互遮挡造成的漏检问题。

2 实验结果与分析

2.1 实验平台

本实验以某型航空发动机装配场景为研究对象,包含12种装配零件,如图7所示将Kinect相机布置于距离操作台平面600mm的高度上,对装配现场进行采集,如图8所示。




图7 实验零件



图8 装配场景

本实验配置环境如表2所示。

表 2 实验配置环境

配置项	型号
编程语言	Python
深度学习框架	Pytorch
操作系统	Win10
CPU	Inter Core i9-9900
运行内存	32 GB
GPU	NVIDIA GeForce RTX 2080Ti

2.2 数据集与实验参数

2.2.1 零件数据集

为减少手工标注时间,采用基于三维模型的虚拟训练集与手工标注真实测试集相结合的方法^[24]。

(1)虚拟训练集构建。虚拟训练集制作过程如图 9 所示,主要流程为:将原始 3D 模型导入到 Unity3D 软件中对零件位姿进行随机调整并拍照后对零件照片裁剪并提取,随机粘贴在装配背景照片上,获得含有零件的合成后照片及零件位置类别信息的 XML 文件。




图 9 虚拟数据集制作流程图

(2)真实测试集采集。利用 Kinect 相机采集真实零件图像作为测试集,如图 8 所示,调节零件与非目标零件位置和角度,从而获取不同状态下的零件图像,在 Labellmg 工具上进行手工标注。

2.2.2 实验参数

实验包含虚拟训练集 2800 张,真实测试集 700 张。含 12 种不同尺度的零件,大部零件为中等尺寸零件,以及螺栓、螺母两种细小零件,具体尺寸规格如表 3 所示。

表 3 零件名称及规格

类型	名称	规格/mm
大尺寸	支架	360 × 175 × 135
	支撑外壳	300 × 240 × 45
	风扇	270 × 270 × 50
	喷嘴	190 × 190 × 52
中尺寸	混合器	175 × 175 × 80
	核心套管	142 × 102 × 95
	燃烧衬砌	115 × 84 × 76
	线管	74 × 74 × 182
	喷嘴锥	98 × 98 × 130
小尺寸	涡轮定子	98 × 98 × 10
	螺栓	5 × 5 × 13
	螺母	5 × 5 × 3

本文训练模型参数设置如下:采用 SGD 优化算法,初始学习率为 0.01;训练批次为 300 次,每个训练批次中一次传入 16 张图片进行训练;输入图片尺寸为 640 × 640,储存最后一次迭代模型权重及最佳性能模型权重。

2.3 评价指标

本实验采用参数量 M、浮点运算数(floating point operations, FLOPs)、mAP 作为模型性能的评价指标,其中 mAP 表示所有类别 AP 值的平均值,mAP 计算公式如下:

$$mAP = \frac{1}{N} \sum_{i=1}^N AP_i \quad (8)$$

$$AP = \int_0^1 P(R) d(R) \quad (9)$$

$$P = \frac{TP}{TP + FP} \quad (10)$$

$$R = \frac{TP}{TP + FN} \quad (11)$$

式中:TP 表示正确预测的数量,FN 表示将正样本预测为负样本的数量,FP 表示将负样本预测为正样本的数量,R 表示查全率,表示将多少正样本正确预测;P 为查准率,表示预测为正的样本中有多少被正确预测。TP、FP 的值根据设定的 IoU 阈值确定,通常为 0.5,计算 mAP 值作为评估指标。

2.4 消融实验

为验证各模块在改进 YOLOv5s 算法中的作用,进行消融实验^[25]观察各模块对于网络性能的影响。本文设置了 4 组对比实验,在依次加入 3 组改进模块后在零件数据集上进行测试,如表 4 所示,“√”表示使用改进的模块。由实验结果可以看出,对比于原有的 YOLOv5s 网络,在依次增加多尺度特征融合、注意力机制模块、优化损失函数与 NMS 后,模型精度提高。在对多尺度特征融合后,mAP 提高了 1.2%,提高了对于小零件的检测精度;在主干网络中融合注意力机制后,由于 Transformer 模块替换掉原始模型中的 Bottleneck 模块,参数量减少,强化特征提取,mAP 提高了 0.7%;在优化损失函数与 NMS 后,在没有大量提高计算参数的情况下,精度提高了 1.0%,一定程度上提高了对于零件被遮挡时的检测性能。综上所述,改进后的检测算法对比原有算法有了明显的提升,且参数量减少。

表 4 基于 YOLOv5s 的消融实验

分组	多尺度特征融合	注意力机制	优化损失函数与 NMS	M / × 10 ⁶	FLOPs / 10 ⁹	mAP / %
1				7.09	16.5	93.3
2	√			7.30	20.0	94.5
3	√	√		6.71	19.5	95.2
4	√	√	√	6.71	19.5	96.2

将各模型训练中的精度和损失值进行对比,如图 10a、图 10b 所示分别为各模型的 mAP 曲线和损失曲线,横坐标代表训练批次,纵坐标分别代表 mAP 和损失值,当训练次数增加时,损失值下降,精度提升,原有算法在 40 个 epoch 前损失值快速下降,精度达到 93% 左右,后续随着训练次数的增加,损失值下降平缓,网络不断拟合,最终精度为 93.3%;加入各模块后,模型的精度依次提高,初始及最终损失值减小,收敛性提高;改进后的算法在 20 个 epoch 时精度即达到 93%,最终损失值下降到 0.018 左右,精度达到 96.2%。与未改进的算法相比,改进之后的算法损失值下降更快,最终损失值更小,且 mAP 值更高,说明网络拟合程度及模型识别性能更好。




图 10 模型 mAP 及损失曲线


2.5 检测结果分析

将 YOLOv5s 算法与改进的 YOLOv5s 算法对不同的零件的检测精度进行对比,如表 5 所示。由表可得,与 YOLOv5s 算法相比,改进后的算法对于大、中尺寸零件 mAP 值变化较小,在对细小螺栓、螺母零件的检测上效果提升显著,分别提高了 12.6%、19.6%。

表 5 两种算法对不同零件的 mAP/% (IoU=0.5) 对比

类别	mAP@0.5/%	
	YOLOv5s	本文算法
支架	99.6	99.5
支撑外壳	99.3	99.5
风扇	99.6	99.5
喷嘴	99.5	99.3
混合器	99.5	99.5
核心套管	99.5	99.4
燃烧衬砌	95.9	94.9
线管	99.6	99.4
喷嘴锥	99.5	99.5
涡轮定子	99.4	99.5
螺栓	71.4	84.0
螺母	56.7	76.3

将改进前后算法得到的训练模型同时在验证集上进行测试,如图 11 所示,其中图 11a 为 YOLOv5s 算法,图 11b 为改进后的算法。



(a) YOLOv5s 算法

(b) 改进后算法

图 11 零件识别结果对比

根据识别结果可得,改进后的算法在对零件检测置信度上有部分提高,且对于小零件的漏检现象减少;当装配场景复杂含有其他物体时,错检漏检率下降,如原算法将机械手误识别为零件而漏检了涡轮定子;当零件被遮挡时,改进后算法也能够准确检测出被遮挡零件。综上表明改进后的算法提高了对于螺栓、螺母等小零件的识别准确性;零件被遮挡时的漏检问题及装配场景杂乱时的错检问题能够得到一定的改善,证明了本文算法的有效性,且每张图片检测时间都在 0.02 s 左右,每秒传输帧数可达到 50,满足实时性要求。

3 结束语

针对增强装配引导系统中场景感知过程中对于复杂装配场景中小零件以及零件被其它物体遮挡造成的错检、漏检问题,提出一种改进 YOLOv5s 的零件检测算法,通过融合注意力机制,增加浅层特征信息并对损失函数与 NMS 进行优化,实验表明改进后的算法一定程度上提高了模型在复杂装配场景下对多尺度零件及零件被遮挡时的检测性能,但当零件被大面积遮挡时检测效果仍不佳,因此未来将在此基础上进行进一步研究。

【参考文献】

[1] 魏祺,郭宇,汤鹏洲,等.增强现实在复杂产品装配领域的关键技术研究与应用综述[J].计算机集成制造系统,

2022,28(3):649-662.



- [2] ZHENG Z H, MA Y, ZHENG H, et al. Industrial part localization and grasping using a robotic arm guided by 2D monocular vision[J]. Industrial Robot: An International Journal, 2018, 45(6): 794-804.
- [3] 陈小佳. 基于视觉的小目标检测方法研究[D]. 杭州: 浙江工业大学, 2020.
- [4] SUN W C, ZHANG Z J, SHI L L, et al. Small sample parts recognition and localization from unfocused images in precision assembly systems using relative entropy[J]. Precision Engineering, 2021, 68: 206-217.
- [5] 田中可, 陈成军, 李东年, 等. 基于深度图像的零件识别及装配监测[J]. 计算机集成制造系统, 2020, 26(2): 300-311.
- [6] 王一, 马钰东, 董光林. 基于改进 Faster RCNN 的零件识别方法研究[J]. 应用光学, 2022, 43(1): 67-73.
- [7] 宋栓军, 侯中原, 王启宇, 等. 改进 YOLOV3 算法在零件识别中的应用[J]. 机械科学与技术, 2021(10): 1608-1604.
- [8] LI Q Y, CHEN G M. Recognition of industrial machine parts based on transfer learning with convolutional neural network[J]. PloS One, 2021, 16(1): 0245735.
- [9] 杨琳, 陈赛旋, 崔国华, 等. 基于改进 YOLOv4 算法的零件识别与定位[J]. 组合机床与自动化加工技术, 2021(10): 28-32.
- [10] SHEU R K, LIN Y C, HUANG C Y, et al. IDS-DLA: sheet metal part identification system for process automation using deep learning algorithms[J]. IEEE Access, 2020, 8: 127329-127342.
- [11] 王向周, 杨敏巍, 郑成华, 等. 基于 YOLOv5s-T 和 RGB-D 相机的螺栓检测与定位系统[J]. 北京理工大学学报, 2022, 42(11): 1159-1166.
- [12] 曾毅星. 面向增强现实应用的轻量级零件识别算法研究[D]. 成都: 电子科技大学, 2021.
- [13] REDMON J, DIVVALA S, GIRSHICK R, et al. You only look once: unified, real-time object detection[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2016.
- [14] REDMON J, FARHADI A. YOLO9000: better, faster, stronger[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, 2017.
- [15] REDMON J, FARHADI A. Yolov3: an incremental improvement[J]. ArXiv Preprint ArXiv, 2018(8): 180402767.
- [16] BOCHKOVSKIY A, WANG C Y, LIAO H Y M. Yolov4: optimal speed and accuracy of object detection[J]. ArXiv Preprint ArXiv, 2020(8): 200410934.
- [17] 余加勇, 刘宝麟, 尹东, 等. 基于 YOLOv5 和 U-Net3+ 的桥梁裂缝智能识别与测量[J/OL]. 湖南大学学报(自然科学版): 1-9 [2023-04-25]. <http://kns.cnki.net/kecms/detail/43.1061.n.20220707.0925.002.html>.
- [18] WOO S, PARK J, LEE J Y, et al. Cham: convolutional block attention module[C]//Proceedings of the European Conference on Computer Vision (ECCV), 2018.
- [19] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. ArXiv Preprint ArXiv, 2017(7): 170603762.
- [20] ZHU X K, LYU S C, WANG X, et al. TPH-YOLOv5: improved YOLOv5 based on transformer prediction head for object detection on drone-captured scenarios[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision, 2021.

(下转第 9 页)

共发生 15 次故障,其故障分布统计如表 5 所示,其中负载水平 S_1 下 7 次,负载水平 S_2 下 8 次,故障时间分别如图 5 和图 6 所示。

表 5 故障分布统计表

序号	故障部位	故障次数	占比/%
1	主轴系统	4	26.6
2	进给轴系统	3	20
3	数控系统	1	6.7
4	电气系统	2	13.3
5	润滑系统	1	6.7
6	其它	4	26.6

图 5 负载水平 S_1 故障发生时间 图 6 负载水平 S_2 故障发生时间

对两种负载水平下的故障数据分别进行最小二乘拟合,对拟合结果采用 K-S 检验后得到威布尔模型参数 $\theta_1 = 364.6, m_1 = 1.22; \theta_2 = 242.47, m_2 = 1.48$ 。

将原始应力和修正应力值分别结合以上威布尔模型参数拟合值,代入式(4)~式(8)计算正常负载水平 S_0 下的分布模型,并与项目组内同型号设备基于负载水平 S_0 开展的现场跟踪统计 1500 h 结果进行对比,威布尔模型参数值如表 6 所示。

表 6 不同方法的威布尔分布参数

	修正应力	原始应力	常规试验
θ	863.26	762.22	824.23
m	1.35	1.35	0.95

利用表 6 中 3 种测评方法的威布尔参数分别绘制得到概率分布函数结果如图 7 所示。




图 7 不同测评方法威布尔分布模型对比

从图 7 中可以得出:

(1) 采用修正应力的加速试验模型较未进行应力修正的模型与跟踪统计常规试验模型相比相差较小,威布尔参数的相对误差分别为 4.7% 和 4.65%,说明本文提出的修正应力具有有效性。

(2) 基于逆幂律模型的两种评估方法计算得到平均无故障时间 MTBF 值分别为 791.6 h、698.95 h,与传统测评方法 841.07 h 相比,相对误差为 5.9% 和 16.9%,可以看出修正应力的测评结果更接近实际。

4 结论

(1) 结合疲劳累积损伤理论,总结了可靠性快速测评试验原理,基于数控机床在不同的运行工况下,各运动轴载荷对整机贡献不同,并提出了应用层次分析法对各运动轴重要度进行赋权,以此进行应力修正。

(2) 提出了基于逆幂律模型的数控机床可靠性快速测评方法,以此设计了试验流程、剖面以及数据采集方式,寿命模型中加速应力采用修正应力结果进一步提高了评估精度。

(3) 在某国产数控弯管机上进行了加速试验与可靠性评估,通过应用 AHP 方法对试验数据中的加速应力进行修正,得到的威布尔形状参数误差为 4.7%,可靠性指标 MTBF 的相对误差为 5.9%,验证了本方法的准确性。

[参考文献]

- [1] 陈传海,王成功,杨兆军,等.数控机床可靠性建模研究现状及发展动态分析[J].吉林大学学报(工学版),2022,52(2):253-266.
- [2] KELLER A Z, KAMATH A R R, PERERA U D. Reliability analysis of CNC machine tools[J]. Reliability Engineering, 1982, 3(6):449-473.
- [3] 贾亚洲,马健,贾志新.数控机床现场故障分布模型的统计研究[J].数理统计与管理,1996(5):25-29.
- [4] 张英芝,申桂香,贾亚洲,等.数控机床故障分布规律及可靠性[J].农业机械学报,2006(1):156-159.
- [5] 于捷,申桂香,贾亚洲.基于三参数威布尔分布的数控机床的可靠性评价[J].现代制造工程,2007(5):18-20.
- [6] 屠国俊,陶卫军,冯虎田,等.基于步进加载的重载滚动直线导轨副可靠性试验方法[J].机床与液压,2012,40(5):4-7,47.
- [7] 李隽,欧屹,韩军.基于威布尔分布模型及小子样增广的滚动直线导轨副可靠性试验研究[J].组合机床与自动化加工技术,2016(12):148-151,156.
- [8] 葛甜.刀库及机械手可靠性综合试验及评估方法研究[D].南京:南京理工大学,2013.
- [9] 陈衡,夏仰球,石纯标.加工中心快速可靠性试验关键技术研究[J].组合机床与自动化加工技术,2021(2):39-42.
- [10] 赵钦志,王立平,王军见.数控机床可靠性试验和评估技术分析[J].制造技术与机床,2017(11):17-21.
- [11] 惠纪庄,孙德仕,邹亚科. Miner 线性累计损伤理论在汽车试验场可靠性试验强化系数研究中的应用[J].工程设计学报,2008(4):264-267.
- [12] 祖莉,肖泽坤,夏仰球.一种基于逆幂律模型的数控机床可靠性快速评估方法:CN114647906A[P].2022-06-21.
- [13] 周大朝,辛庆伟,邢诺贝,等.机床伺服进给系统在机可靠性加速试验与评估方法[J].机械制造,2020,58(5):73-76,96. (编辑 祝智铭)

(上接第 5 页)

- [21] 彭成,张乔虹,唐朝晖,等.基于 YOLOv5 增强模型的口罩佩戴检测方法研究[J].计算机工程,2022,48(4):39-49.
- [22] 郭磊,王邱龙,薛伟,等.基于改进 YOLOv5 的小目标检测算法[J].电子科技大学学报,2022,51(2):251-258.
- [23] ZHENG Z H, WANG P, LIU W, et al. Distance-IoU loss: faster and better learning for bounding box regression[C]// Proceedings of the AAAI Conference on Artificial Intelligence, 2020.

- [24] 李昌明,李东年,陈成军,等.基于卷积神经网络与虚拟训练集的零件识别[J].组合机床与自动化加工技术,2021(8):40-43.
- [25] REN S Q, HE K M, GIRSHICK R, et al. Faster R-CNN: towards real-time object detection with region proposal networks[J]. IEEE Transactions on Pattern Analysis & Machine Intelligence, 2017, 39(6):1137-1149. (编辑 祝智铭)